N^o d'ordre : /2026

République Algérienne Démocratique et Populaire

Ministère de L'Enseignement Supérieur et de la Recherche Scientifique

Université des Sciences et de la Technologie HOUARI BOUMEDIENE

Faculté d'Informatique – Département d'Informatique

Mémoire de Fin d'Études

Présenté en vue de l'obtention du diplôme de **MASTER**

Domaine : Mathématiques et Informatique

Filière : Informatique

Spécialité : Vision par Ordinateur et Intelligence Artificielle

Réalisé par : NOM Prénom

En partenariat avec : **Sonatrach – Direction Recherche & Développement, Boumerdès, Algérie**

Thème

Système Intelligent Basé sur le Deep Learning pour la Détection des Torchères Industrielles et l'Évaluation Automatique de la Qualité de Combustion

Soutenu publiquement, le **/06/2026**, devant le jury composé de :

M.	NOM Prénom	Maître de Conférences/A	à l'USTHB	Président
M.	NOM Prénom	Maître de Conférences/A	à l'USTHB	Encadreur
M.	NOM Prénom	Ingénieur Chercheur	à Sonatrach R&D	Co-encadreur
M.	NOM Prénom	Maître de Conférences/B	à l'USTHB	Examinateur

Année Universitaire : 2025/2026

À mes très chers parents,
qui m'ont toujours soutenu et encouragé
à surmonter tous les obstacles.
Que Dieu les garde et les protège.

À mes frères et sœurs,
pour leur affection et leur soutien indéfectible.

À tous mes amis et camarades de promotion,
qui ont partagé avec moi les joies et les peines
de ce long parcours universitaire.

Je dédie ce modeste travail.

Remerciements

Au terme de ce travail, je tiens à exprimer ma profonde gratitude à toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce mémoire.

Je remercie en premier lieu **Prof. NOM Prénom**, encadreur universitaire, Maître de Conférences au Département d'Informatique de la Faculté d'Informatique de l'USTHB, pour sa disponibilité, ses précieux conseils scientifiques, ses encouragements constants et la confiance qu'il m'a accordée tout au long de ce projet. Ses orientations judicieuses et son expertise en vision par ordinateur et en deep learning ont été déterminantes pour la qualité de ce travail.

Je remercie également **M. NOM Prénom**, encadreur industriel, Ingénieur Chercheur à la Direction Recherche & Développement de **Sonatrach** à Boumerdès, pour m'avoir accueilli au sein de son équipe, pour son accompagnement technique rigoureux et pour avoir partagé avec moi sa connaissance approfondie du contexte industriel pétrolier et gazier algérien. Son soutien et ses remarques pertinentes ont été d'une valeur inestimable.

Mes sincères remerciements vont aux membres du jury :

— **M. NOM Prénom**, Maître de Conférences/A à l'USTHB, pour avoir accepté de présider ce jury.

— **M. NOM Prénom**, Maître de Conférences/B à l'USTHB, pour avoir accepté d'examiner ce travail.

Je tiens à remercier l'ensemble des enseignants du Département d'Informatique de l'USTHB, et plus particulièrement ceux de la spécialité Vision par Ordinateur et Intelligence Artificielle, pour la qualité de la formation dispensée.

Enfin, je remercie de tout cœur ma famille pour son soutien moral et ses encouragements tout au long de mon cursus universitaire.

L'Auteur

Résumé

Ce mémoire présente la conception et l'implémentation d'un système intelligent basé sur le deep learning pour la détection automatique des torchères industrielles (*gas flares*) et l'évaluation visuelle de la qualité de combustion. Réalisé en partenariat avec la Direction Recherche & Développement de Sonatrach à Boumerdès, ce travail répond à un besoin industriel critique en matière de surveillance environnementale et de sécurité des installations pétrolières et gazières.
Le système propose un pipeline à deux étages : (1) une étape de détection des torchères par des modèles YOLO (*You Only Look Once*), permettant la localisation précise des flammes dans des images RGB et des séquences vidéo ; (2) une étape d'évaluation de la qualité de combustion basée sur des réseaux de neurones convolutifs (CNN), complétée par une approche hybride intégrant segmentation sémantique, extraction d'indicateurs visuels (ratio flamme/fumée, histogrammes HSV, texture GLCM) et classification par SVM.
Les expérimentations réalisées sur des jeux de données publics annotés démontrent l'efficacité du système proposé, avec des performances compétitives en termes de mAP, précision, rappel et F1-score. Les résultats confirment la faisabilité d'un système de surveillance automatisé et non-intrusif applicable dans un contexte industriel réel.

Mots-clés : Deep Learning, Détection d'objets, YOLO, Torchères industrielles, Gas flares, Qualité de combustion, Vision par ordinateur, Segmentation sémantique, CNN, Sonatrach.

Abstract

This thesis presents the design and implementation of an intelligent deep learning-based system for the automatic detection of industrial flares (gas flares) and the visual assessment of combustion quality. Carried out in partnership with Sonatrach's Research & Development Division in Boumerdès, this work addresses a critical industrial need for environmental monitoring and safety of oil and gas facilities.
The proposed system implements a two-stage pipeline: (1) a flare detection stage using YOLO (You Only Look Once) models, enabling precise localization of flames in RGB images and video sequences; (2) a combustion quality assessment stage based on convolutional neural networks (CNN), complemented by a hybrid approach integrating semantic segmentation, extraction of visual indicators (flame-to-smoke ratio, HSV histograms, GLCM texture features) and SVM-based classification.
Experiments conducted on annotated public datasets demonstrate the effectiveness of the proposed system, achieving competitive performance in terms of mAP, precision, recall and F1-score. Results confirm the feasibility of an automated, non-intrusive monitoring system deployable in a real industrial context.

Table des matières

Remerciements

Table des figures i

Liste des tableaux ii

Liste des Algorithmes iii

Nomenclature iv

Introduction Générale 1

1 Contexte Industriel et Problématique 4

1.1 Introduction 4

1.2 Présentation de Sonatrach 4

1.2.1 Historique et statut 4

1.2.2 Organisation et activités 4

1.2.3 Direction Recherche & Développement 5

1.3 Les Torchères Industrielles 5

1.3.1 Définition et rôle technique 5

1.3.2 Fonctionnement et paramètres de combustion 6

1.3.3 Types de torchères 6

1.4 Enjeux Environnementaux et Réglementaires 6

1.4.1 Impacts environnementaux 6

1.4.2 Cadre réglementaire 7

1.5 Formulation du Problème Scientifique 7

1.5.1 Limitations des approches actuelles 7

1.5.2 Problème scientifique posé 8

1.5.3 Hypothèses de travail 8

1.6 Objectifs et Contributions 8

1.6.1 Objectifs du système 8
1.6.2 Contributions attendues 9
1.7 Conclusion 9
1.8 Conclusion 10

2 État de l'Art **11**
2.1 Introduction 11
2.2 Vision par Ordinateur 11
2.2.1 Définition et domaines d'application 11
2.2.2 Traitement d'image classique 12
2.3 Deep Learning 12
2.3.1 Fondements des réseaux de neurones profonds 12
2.3.2 Réseaux de Neurones Convolutifs (CNN) 12
2.3.3 Architectures CNN emblématiques 12
2.4 Détection d'Objets 13
2.4.1 Approches à deux étapes (two-stage detectors) 13
2.4.2 Approches à une étape (one-stage detectors) 14
2.5 Segmentation Sémantique et d'Instances 15
2.5.1 U-Net 15
2.5.2 DeepLab 15
2.6 Analyse de Combustion par Vision Artificielle 15
2.6.1 Caractérisation visuelle de la flamme 15
2.6.2 Approches d'apprentissage pour la qualité de combustion 16
2.7 Travaux Liés à la Surveillance des Torchères 16
2.7.1 Détection de torchères par satellite 16
2.7.2 Vision par ordinateur appliquée aux torchères 17
2.7.3 Tableau récapitulatif des travaux liés 17
2.8 Analyse Critique et Positionnement 17
2.9 Conclusion 18

3 Méthodologie Proposée **19**
3.1 Introduction 19
3.2 Architecture Globale du Système 19
3.2.1 Vue d'ensemble 19
3.2.2 Prétraitement des données 20
3.3 Module A : Détection des Torchères par YOLOv8 20
3.3.1 Justification du choix de YOLOv8 20

3.3.2 Architecture de YOLOv8 21
3.3.3 Stratégie d'entraînement 21
3.3.4 Métriques d'évaluation de la détection 22
3.4 Module B : Évaluation de la Qualité de Combustion 23
3.4.1 Taxonomie des qualités de combustion 23
3.4.2 Approche 1 : Classification par CNN (*fine-tuned*) 23
3.4.3 Approche 2 : Méthode Hybride (Segmentation + Extraction de Caractéristiques + Classification) 24
3.4.4 Analyse Temporelle (Extension Avancée) 25
3.5 Comparaison Prévue des Approches 25
3.6 Conclusion 25

4 Implémentation et Expérimentation 27
4.1 Introduction 27
4.2 Environnement de Développement 27
4.2.1 Configuration matérielle 27
4.2.2 Environnement logiciel 28
4.3 Jeux de Données 28
4.3.1 Description des données utilisées 28
4.3.2 Statistiques du jeu de données 29
4.4 Paramètres d'Entraînement 29
4.4.1 Paramètres du Module A – YOLOv8 29
4.4.2 Paramètres du Module B – CNN (Approche 1) 30
4.4.3 Paramètres du Module B – Approche Hybride (Approche 2) 30
4.5 Résultats Expérimentaux 31
4.5.1 Résultats du Module A – Détection par YOLOv8 31
4.5.2 Résultats du Module B – Évaluation de la Qualité de Combustion . 32
4.6 Analyse des Résultats et Comparaison 33
4.6.1 Comparaison globale des approches 33
4.6.2 Analyse des cas difficiles 34
4.7 Conclusion 34

5 Discussion et Perspectives 35
5.1 Introduction 35
5.2 Analyse Critique des Résultats 35
5.2.1 Forces du système proposé 35
5.2.2 Limites identifiées 36

5.3 Robustesse Industrielle et Déployabilité 37
5.3.1 Contraintes du contexte industriel Sonatrach 37
5.3.2 Stratégie de déploiement envisagée 38
5.4 Perspectives d'Amélioration 38
5.4.1 Perspectives à court terme (6–12 mois) 38
5.4.2 Perspectives à moyen terme (1–2 ans) 39
5.4.3 Perspectives à long terme (au-delà de 2 ans) 39
5.5 Positionnement par Rapport à la Littérature 40
5.6 Conclusion 40

Conclusion Générale **41**

Bibliographie **43**

A Hyperparamètres et Configurations Détaillées **46**
A.1 Configuration complète de YOLOv8 46
A.2 Script d'entraînement YOLOv8 46
A.3 Algorithme d'extraction des caractéristiques HSV+GLCM 47
A.4 Title of the section 48

B Métriques d'Évaluation et Résultats Complémentaires **50**
B.1 Définitions formelles des métriques 50
B.1.1 Métriques de détection d'objets 50
B.1.2 Métriques de classification 50
B.2 Résultats par classe – Tableau détaillé 51
B.3 Courbes Précision-Rappel 52

Table des figures

1.1 Short title of the figure 10

3.1 Architecture globale du pipeline 20

4.1 Courbes d'apprentissage YOLOv8 31
4.2 Exemples de détections 32
4.3 Matrice de confusion ResNet-50 33

A.1 Short title of the figure 48

B.1 Courbes Précision-Rappel 52

Liste des tableaux

1.1 Les paramètres du module photovoltaïque 10

2.1 Synthèse comparative des travaux liés à la surveillance de combustion par vision artificielle 17

3.1 Techniques d'augmentation de données appliquées lors de l'entraînement . 22
3.2 Taxonomie des classes de qualité de combustion 23
3.3 Grille de comparaison des approches d'évaluation de la qualité de combustion 25

4.1 Configuration matérielle de la plateforme d'expérimentation 27
4.2 Environnement logiciel utilisé 28
4.3 Statistiques du jeu de données global 29
4.4 Hyperparamètres d'entraînement du module de détection (YOLOv8) . . . 29
4.5 Hyperparamètres d'entraînement du module de classification CNN (ResNet-50) 30
4.6 Performances du module de détection YOLOv8 sur le jeu de test 31
4.7 Performances de classification de la qualité de combustion – Approche CNN 32
4.8 Performances de classification de la qualité de combustion – Approche Hybride 33
4.9 Tableau comparatif final des approches d'évaluation de la qualité de combustion 33

5.1 Modes de déploiement envisagés et leurs caractéristiques 38

A.1 Les paramètres du module photovoltaïque 49

B.1 Résultats de classification par classe (ResNet-50, jeu de test) 51

Liste des Algorithmes

A.1 Extraction du vecteur de caractéristiques visuelles 48

Nomenclature

Acronymes / Abréviations

Adam	Adaptive Moment Estimation
API	Application Programming Interface
BN	Batch Normalization (Normalisation par Lot)
BN	Batch Normalization (Normalisation par Lot)
BS	Batch Size (Taille de Lot)
CNN	Réseau de Neurones Convolutif (Convolutional Neural Network)
CNN	Réseau de Neurones Convolutif (Convolutional Neural Network)
CPU	Central Processing Unit (Unité Centrale de Traitement)
CPU	Central Processing Unit (Unité Centrale de Traitement)
DL	Deep Learning (Apprentissage Profond)
FC	Fully Connected (Entièrement Connecté)
FC	Fully Connected (Entièrement Connecté)
FPN	Feature Pyramid Network
FPN	Feature Pyramid Network
GAN	Generative Adversarial Network (Réseau Antagoniste Génératif)
GF	Gas Flare (Torchère industrielle)
GLCM	Gray-Level Co-occurrence Matrix (Matrice de Co-occurrence des Niveaux de Gris)
GLCM	Gray-Level Co-occurrence Matrix
GPU	Graphics Processing Unit (Unité de Traitement Graphique)

GPU	Graphics Processing Unit (Unité de Traitement Graphique)
HSV	Hue Saturation Value (Teinte Saturation Valeur)
HSV	Hue Saturation Value (Teinte Saturation Valeur)
IoU	Intersection over Union
IoU	Intersection over Union
LR	Learning Rate (Taux d'Apprentissage)
LSTM	Long Short-Term Memory
LSTM	Long Short-Term Memory
mAP	Mean Average Precision (Précision Moyenne Globale)
NMS	Non-Maximum Suppression (Suppression des Non-Maxima)
NMS	Non-Maximum Suppression (Suppression des Non-Maxima)
PANet	Path Aggregation Network
PANet	Path Aggregation Network
RCNN	Region-based Convolutional Neural Network
ReLU	Rectified Linear Unit (Unité Linéaire Rectifiée)
RGB	Red Green Blue (Modèle colorimétrique)
RNN	Réseau de Neurones Récurrent (Recurrent Neural Network)
ROI	Region of Interest (Région d'Intérêt)
ROI	Region of Interest (Région d'Intérêt)
SGD	Stochastic Gradient Descent (Descente de Gradient Stochastique)
SGD	Stochastic Gradient Descent (Descente de Gradient Stochastique)
SSD	Single Shot multibox Detector
SSD	Single Shot multibox Detector
SVM	Support Vector Machine
SVM	Support Vector Machine
VOC	Composés Organiques Volatils
VOC	Composés Organiques Volatils

WD	Weight Decay (Décroissance des Poids)
YOLO	You Only Look Once
YOLO	You Only Look Once

Introduction Générale

Contexte général

Dans un contexte mondial de transition énergétique et de renforcement des réglementations environnementales, les industries extractives, et en particulier le secteur pétrolier et gazier, font face à une pression croissante pour réduire leur empreinte carbone et améliorer l'efficacité de leurs procédés. Les torchères industrielles, dispositifs de combustion à l'air libre utilisés pour brûler les excédents de gaz, représentent l'une des sources les plus visibles d'émissions atmosphériques dans ce secteur. En Algérie, Sonatrach, entreprise nationale des hydrocarbures, opère de nombreuses torchères sur l'ensemble de ses sites de production et de raffinage. La surveillance de ces installations est un impératif à la fois sécuritaire, réglementaire et environnemental.

Traditionnellement, le contrôle de la qualité de combustion de ces torchères est assuré par des inspections visuelles humaines, procédures coûteuses, subjectives et potentiellement dangereuses. L'avènement du deep learning et de la vision par ordinateur ouvre la voie à des systèmes de surveillance automatisés, capables d'analyser en continu des flux d'images ou de vidéos et d'en extraire des indicateurs objectifs sur la qualité de combustion.

Motivation et problématique

La problématique centrale de ce mémoire peut être formulée de la manière suivante : comment concevoir un système intelligent, basé sur des techniques modernes de deep learning et de vision par ordinateur, capable de détecter automatiquement les torchères industrielles dans des images RGB et d'évaluer de manière fiable la qualité de leur combustion, en distinguant notamment les flammes propres des phénomènes de fumée noire signe d'une combustion incomplète et polluante ?

Deux difficultés techniques majeures se posent. D'une part, la détection des torchères dans des environnements industriels complexes nécessite des modèles robustes aux varia-

tions d'éclairage, d'échelle et de perspective. D'autre part, l'évaluation qualitative de la combustion requiert l'extraction et l'interprétation de caractéristiques visuelles fines telles que la couleur, la texture et la morphologie de la flamme et de la fumée associée.

Objectifs du mémoire

Ce travail poursuit les objectifs suivants :

1. Concevoir et implémenter un module de détection automatique des torchères industrielles par des modèles de détection d'objets de type YOLO (*You Only Look Once*).
2. Développer un module d'évaluation de la qualité de combustion à partir d'indicateurs visuels extraits des régions d'intérêt (ROI), en exploitant des architectures CNN et des approches hybrides.
3. Comparer les performances des différentes approches proposées sur des jeux de données annotés.
4. Proposer un système intégré, modulaire et extensible, adapté au contexte opérationnel de Sonatrach.

Organisation du mémoire

Ce mémoire est organisé en cinq chapitres, précédés d'une introduction générale et suivis d'une conclusion générale :

— **Chapitre 1 : Contexte industriel et problématique.** Ce chapitre présente le cadre industriel du projet avec une description de Sonatrach et de ses activités, le fonctionnement des torchères industrielles, les enjeux environnementaux associés et la formulation précise du problème scientifique traité.

— **Chapitre 2 : État de l'art.** Ce chapitre passe en revue les travaux académiques et techniques pertinents, couvrant les domaines de la vision par ordinateur, du deep learning, de la détection d'objets, de la segmentation sémantique et de l'analyse de combustion par vision artificielle.

— **Chapitre 3 : Méthodologie proposée.** Ce chapitre détaille l'architecture globale du système proposé, le pipeline de traitement, les modèles retenus et les justifications des choix techniques effectués.

— **Chapitre 4 : Implémentation et expérimentation.** Ce chapitre décrit l'environnement matériel et logiciel utilisé, les jeux de données, les paramètres d'en-

traînement et présente les résultats expérimentaux ainsi qu'une comparaison des différentes approches.

— **Chapitre 5 : Discussion et perspectives.** Ce chapitre propose une analyse critique des résultats, identifie les limites du système, évalue sa robustesse dans un contexte industriel réel et ouvre des perspectives d'amélioration.

Chapitre 1

Contexte Industriel et Problématique

1.1 Introduction

Le premier chapitre de ce mémoire a pour vocation d'établir le cadre industriel dans lequel s'inscrit notre projet de fin d'études. Il présente l'entreprise partenaire, Sonatrach, et son positionnement stratégique dans l'économie algérienne. Il décrit ensuite le fonctionnement technique des torchères industrielles, leurs rôles dans la sécurité des installations, ainsi que les problèmes environnementaux qu'elles engendrent. Enfin, il formule précisément la problématique scientifique et les objectifs du système proposé.

1.2 Présentation de Sonatrach

1.2.1 Historique et statut

La Société Nationale pour la Recherche, la Production, le Transport, la Transformation et la Commercialisation des Hydrocarbures, connue sous le sigle **Sonatrach**, a été fondée en 1963, soit peu après l'indépendance de l'Algérie. Elle constitue aujourd'hui la première entreprise africaine et la onzième mondiale dans le secteur des hydrocarbures. Sonatrach assure la quasi-totalité de la production d'hydrocarbures en Algérie et contribue de manière substantielle aux recettes en devises du pays.

1.2.2 Organisation et activités

L'entreprise est organisée autour de plusieurs activités complémentaires :

— **Exploration et Production (Amont)** : prospection, forage et exploitation des gisements de pétrole brut et de gaz naturel, principalement dans le bassin saharien (Hassi Messaoud, Hassi R'Mel, In Amenas, etc.).

— **Transport par Canalisations (TRC)** : gestion d'un réseau de gazoducs et d'oléoducs couvrant l'ensemble du territoire national.
— **Liquéfaction, Raffinage et Pétrochimie (Aval)** : transformation des hydrocarbures dans des complexes industriels à Skikda, Arzew et Bejaia.
— **Commercialisation** : exportation de gaz naturel liquéfié (GNL), de gaz naturel par pipelines et de pétrole brut vers l'Europe et les marchés internationaux.

1.2.3 Direction Recherche & Développement

La Direction Recherche & Développement (R&D) de Sonatrach, dont le siège est situé à **Boumerdès**, constitue la branche scientifique et technologique de l'entreprise. Elle est chargée de mener des études sur les procédés industriels, de développer des solutions innovantes pour améliorer l'efficacité opérationnelle, et de contribuer à la transition numérique de Sonatrach. Dans ce cadre, le présent projet de fin d'études s'inscrit dans un axe de recherche appliquée portant sur l'utilisation de l'intelligence artificielle pour la surveillance automatisée des installations industrielles.

1.3 Les Torchères Industrielles

1.3.1 Définition et rôle technique

Une torchère industrielle (en anglais : *gas flare*) est un dispositif de combustion à l'air libre utilisé dans les raffineries, les plateformes pétrolières, les usines pétrochimiques et les sites de production de gaz pour brûler les excédents de gaz combustibles qui ne peuvent pas être récupérés, traités ou exportés dans l'immédiat. Ce gaz excédentaire est principalement composé de méthane (CH_4), d'éthane (C_2H_6), de propane (C_3H_8) et d'autres hydrocarbures.

D'un point de vue sécuritaire, les torchères remplissent plusieurs fonctions essentielles :

1. **Sécurité et prévention des surpressions** : en cas de montée en pression imprévue dans un procédé, le gaz est dirigé et brûlé en urgence via la torchère, évitant ainsi toute explosion ou rupture d'équipement.
2. **Démarrage et arrêt des installations** : lors des phases transitoires de démarrage ou d'arrêt d'une unité, les gaz non encore conformes sont orientés vers la torchère.
3. **Gestion des gaz de dégagement** : certains procédés génèrent des gaz résiduels dont la valorisation économique est complexe et qui sont donc torchés.

1.3.2 Fonctionnement et paramètres de combustion

Le rendement d'une torchère est principalement exprimé par son **efficacité de combustion**, définie comme le ratio de la quantité de carbone effectivement oxydée en CO_2 par rapport au carbone total introduit dans la flamme. Une bonne combustion se caractérise par une flamme lumineuse de couleur orangée à jaune, tandis qu'une combustion incomplète se traduit par l'émission de **fumée noire** (suie), signe de la formation de particules de carbone non brûlées.

Les principaux paramètres influençant la qualité de combustion sont :

— Le débit et la composition du gaz torché ;
— La vitesse et la direction du vent ;
— L'injection d'air ou de vapeur d'eau pour améliorer le mélange ;
— La géométrie du brûleur (torchère à pointe, torchère à jet, etc.).

1.3.3 Types de torchères

On distingue principalement les types suivants :

— **Torchères à pointe ouverte** (*open-tip flares*) : les plus répandues, simples et robustes ; la combustion se fait directement à l'extrémité d'un tuyau vertical.
— **Torchères à injection de vapeur** (*steam-assisted flares*) : de la vapeur est injectée pour améliorer le mélange et réduire la formation de fumée noire.
— **Torchères en fosse** (*enclosed flares*) : la flamme est confinée, ce qui réduit les émissions visibles mais rend la surveillance visuelle difficile.
— **Torchères à jet de gaz** (*air-assisted flares*) : utilisent de l'air insufflé pour améliorer la combustion.

1.4 Enjeux Environnementaux et Réglementaires

1.4.1 Impacts environnementaux

Le torchage représente un phénomène à la fois énergétique et environnemental préoccupant. Selon l'Agence Internationale de l'Énergie (AIE), les volumes de gaz torchés au niveau mondial s'élèvent à environ 140 milliards de mètres cubes par an, représentant une perte énergétique considérable et une source majeure d'émissions de gaz à effet de serre.

Les principaux impacts environnementaux sont :

— **Émissions de** CO_2 : une combustion complète génère du dioxyde de carbone, contribuant au réchauffement climatique.

— **Émissions de méthane non brûlé** : en cas de combustion incomplète, le méthane – gaz à effet de serre 84 fois plus puissant que le CO_2 sur 20 ans – est rejeté directement dans l'atmosphère.
— **Formation de suie et de particules fines ($PM_{2.5}$)** : la fumée noire contient des hydrocarbures aromatiques polycycliques (HAP), des composés organiques volatils (VOC) et des métaux lourds néfastes pour la santé.
— **Nuisances lumineuses et sonores** : impact sur les populations riveraines des sites industriels.

1.4.2 Cadre réglementaire

Sur le plan international, des réglementations de plus en plus strictes encadrent le torchage :

— La **Banque Mondiale** soutient l'initiative *Zero Routine Flaring by 2030*, à laquelle de nombreuses compagnies pétrolières internationales ont adhéré.
— L'**Agence de Protection de l'Environnement américaine (EPA)** impose des normes techniques sur l'efficacité de combustion des torchères (supérieure à 98%).
— En Algérie, le **décret exécutif n°06-02 du 7 janvier 2006** relatif aux émissions atmosphériques impose des limites sur les volumes de gaz torchés et les polluants émis.

La surveillance du respect de ces normes nécessite un suivi régulier et documenté des conditions de fonctionnement des torchères, justifiant le développement de systèmes de monitoring automatisés.

1.5 Formulation du Problème Scientifique

1.5.1 Limitations des approches actuelles

La surveillance des torchères est actuellement assurée par des opérateurs humains qui effectuent des rondes d'inspection périodiques sur site ou analysent manuellement des enregistrements vidéo. Cette approche présente plusieurs limitations majeures :

— **Subjectivité** : l'évaluation visuelle de la qualité de combustion dépend de l'expérience et du jugement de l'opérateur.
— **Discontinuité** : les inspections ne sont pas permanentes, laissant des plages temporelles non surveillées.
— **Dangerosité** : la proximité des torchères en fonctionnement représente un risque pour la sécurité du personnel.

— **Coût** : le maintien d'une surveillance humaine continue est économiquement prohibitif.
— **Non scalabilité** : un même opérateur ne peut surveiller simultanément un grand nombre de torchères sur un vaste site industriel.

1.5.2 Problème scientifique posé

Le problème scientifique traité dans ce mémoire peut être décomposé en deux sous-problèmes distincts mais complémentaires :

Sous-problème 1 – Détection automatique des torchères :

Étant donné une image ou une séquence vidéo issue d'une caméra RGB positionnée sur un site industriel pétrolier, comment localiser automatiquement et avec précision la ou les torchères présentes dans la scène, en fournissant leurs coordonnées spatiales et les boîtes englobantes correspondantes ?

Sous-problème 2 – Évaluation de la qualité de combustion :

Étant donné la région d'intérêt (ROI) d'une torchère détectée, comment quantifier automatiquement la qualité de combustion en attribuant un label parmi plusieurs classes prédéfinies (bonne combustion, combustion partielle, mauvaise combustion) à partir d'indicateurs visuels objectivement mesurables ?

1.5.3 Hypothèses de travail

Les hypothèses suivantes sont retenues dans le cadre de ce travail :

— Les images sont acquises en conditions diurnes ou nocturnes par des caméras RGB standard, avec une résolution suffisante pour distinguer flamme et fumée.
— La vérité terrain est fournie sous forme d'annotations de type boîte englobante pour la détection et de labels de classe pour la classification de la combustion.
— Les données d'entraînement sont issues de jeux de données publics annotés, complétés si nécessaire par des annotations manuelles sur des images représentatives.

1.6 Objectifs et Contributions

1.6.1 Objectifs du système

Le système proposé dans ce mémoire vise à :

1. Détecter automatiquement les torchères en temps réel sur des images ou séquences vidéo.

2. Extraire la région d'intérêt (ROI) de la flamme détectée pour une analyse fine.
3. Classifier la qualité de combustion selon une taxonomie définie en concertation avec les experts de Sonatrach.
4. Proposer une interface de résultats exploitable pour les opérateurs de terrain.

1.6.2 Contributions attendues

Les contributions scientifiques de ce mémoire sont les suivantes :

— Application et adaptation de modèles YOLO (v8) à la détection de torchères industrielles dans des conditions visuelles variables.
— Proposition d'un pipeline complet d'évaluation de la qualité de combustion, combinant extraction de caractéristiques visuelles et deep learning.
— Évaluation comparative de plusieurs approches (CNN, méthodes hybrides) sur des jeux de données annotés.
— Analyse de l'applicabilité du système dans un contexte industriel réel.

1.7 Conclusion

Ce chapitre a posé les bases contextuelles et scientifiques du présent travail. Il a présenté l'entreprise Sonatrach et son centre de recherche et développement partenaire, décrit le fonctionnement et les types de torchères industrielles, analysé leurs impacts environnementaux et le cadre réglementaire qui les régit, et formulé précisément la problématique scientifique abordée. Le chapitre suivant dresse un état de l'art des approches existantes en vision par ordinateur et en deep learning susceptibles d'apporter des solutions à cette problématique.

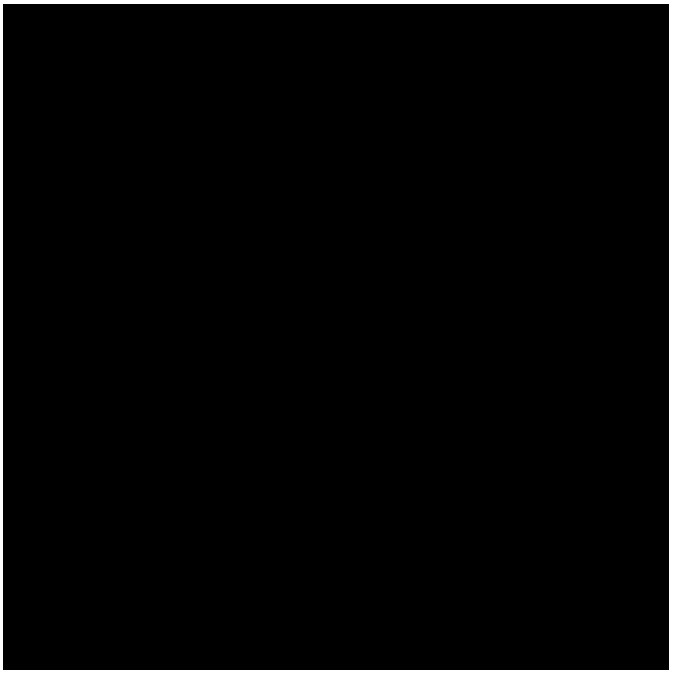

Figure 1.1 – Long title of the figure

Tableau 1.1 – Les paramètres du module photovoltaïque

Paramètres	Valeurs	Unités
P_{mp}	100	W
V_{oc}	13.3	V
I_{sc}	9.8	A

1.8 Conclusion

Qu'est que c'est?. C'est une phrase français avant le lorem ipsum. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Chapitre 2

État de l'Art

2.1 Introduction

Ce chapitre présente une synthèse des principaux travaux et avancées technologiques en lien direct avec la problématique de ce mémoire. Après un rappel des fondements de la vision par ordinateur, nous décrivons les architectures de deep learning pertinentes, les méthodes de détection d'objets, les techniques de segmentation sémantique, puis nous nous focalisons sur l'état de l'art spécifique à l'analyse de combustion et à la surveillance des torchères industrielles par vision artificielle.

2.2 Vision par Ordinateur

2.2.1 Définition et domaines d'application

La vision par ordinateur (*Computer Vision*) est un domaine de l'intelligence artificielle qui vise à doter les machines d'une capacité d'interprétation et de compréhension du monde visuel à partir d'images numériques ou de séquences vidéo. Ses applications couvrent des domaines aussi variés que la robotique, la médecine, la conduite autonome, la surveillance industrielle et la télédétection [1].

Les tâches fondamentales de la vision par ordinateur incluent :

— **Classification d'images** : attribuer un label global à une image.

— **Détection d'objets** : localiser et identifier des objets dans une image par des boîtes englobantes (*bounding boxes*).

— **Segmentation sémantique** : attribuer un label à chaque pixel de l'image.

— **Segmentation d'instances** : distinguer les différentes instances d'un même objet.

— **Estimation de pose** et **suivi d'objets** (*tracking*).

2.2.2 Traitement d'image classique

Avant l'avènement du deep learning, le traitement d'image reposait sur des descripteurs artisanaux (*handcrafted features*) tels que SIFT [2], HOG [3] ou LBP (*Local Binary Patterns*), combinés à des classificateurs classiques (SVM, forêts aléatoires). Ces approches, bien que performantes dans des conditions contrôlées, montrent des limites face à la variabilité inter-image, aux occlusions et aux conditions d'éclairage changeantes.

2.3 Deep Learning

2.3.1 Fondements des réseaux de neurones profonds

Le deep learning est une branche de l'apprentissage automatique basée sur des réseaux de neurones artificiels à plusieurs couches (*deep neural networks*). L'apprentissage consiste à ajuster les poids synaptiques par rétropropagation du gradient (*backpropagation*) afin de minimiser une fonction de perte [4]. La disponibilité de grandes quantités de données annotées (ImageNet, COCO) et de ressources de calcul GPU a rendu possible l'entraînement de modèles très profonds.

2.3.2 Réseaux de Neurones Convolutifs (CNN)

Les CNN sont des architectures spécialement conçues pour le traitement des images. Ils exploitent les structures spatiales locales grâce à :

- Des **couches de convolution** : extraction de caractéristiques locales par filtres apprenables.
- Des **couches de pooling** : réduction de la dimensionnalité spatiale (max-pooling, average-pooling).
- Des **couches entièrement connectées** (*fully-connected*) : classification finale.
- Des fonctions d'activation non-linéaires (*ReLU*, *Sigmoid*, *Softmax*).

2.3.3 Architectures CNN emblématiques

2.3.3.1 VGGNet

Le réseau VGG [5], proposé par le Visual Geometry Group de l'Université d'Oxford, est caractérisé par l'utilisation exclusive de petits filtres convolutifs 3×3 empilés en séquence. Dans sa version VGG-16, le réseau compte 16 couches avec poids apprenables. Malgré sa simplicité conceptuelle, VGG-16 demeure une architecture de référence pour l'extraction de caractéristiques visuelles.

2.3.3.2 ResNet

Définition 2.1. Un **bloc résiduel** (*residual block*) est une unité de construction d'un réseau ResNet dans laquelle la sortie d'un ensemble de couches est additionnée à l'entrée de ce même ensemble (connexion de court-circuit ou *skip connection*), permettant d'éviter le problème de la disparition du gradient lors de l'entraînement de réseaux très profonds [6].

ResNet (*Residual Network*) a été introduit par He et al. [6] et a remporté le challenge ImageNet ILSVRC 2015. Les connexions résiduelles permettent d'entraîner des réseaux comportant plus de 100 couches (ResNet-50, ResNet-101, ResNet-152) sans dégradation des performances. ResNet est aujourd'hui largement utilisé comme encodeur (*backbone*) dans de nombreuses architectures de détection et de segmentation.

2.3.3.3 EfficientNet

Proposé par Tan et Le [7], EfficientNet introduit une méthode de mise à l'échelle composée (*compound scaling*) qui équilibre de manière optimale la profondeur, la largeur et la résolution du réseau. La famille EfficientNet (B0 à B7) offre un excellent compromis précision/efficacité computationnelle, surpassant des modèles bien plus lourds sur le benchmark ImageNet.

2.4 Détection d'Objets

2.4.1 Approches à deux étapes (two-stage detectors)

2.4.1.1 R-CNN et ses variantes

Girshick et al. [8] ont introduit R-CNN (*Region-based CNN*), qui applique un CNN sur des régions candidates générées par la méthode de recherche sélective (*selective search*). Cette approche souffrait d'une grande lenteur d'exécution. Fast R-CNN [9] a amélioré l'efficacité en partageant le calcul de la carte de caractéristiques entre les régions candidates. Faster R-CNN [10] a finalement intégré un module **RPN** (*Region Proposal Network*) au sein du réseau, supprimant la dépendance à un algorithme externe de génération de propositions et atteignant des performances temps-réel partielles.

Remarque. Faster R-CNN reste l'architecture de référence pour la détection d'objets dans les benchmarks PASCAL VOC et MS COCO, avec un mAP supérieur à 80% sur VOC 2012, mais présente des latences d'inférence trop élevées pour les applications temps-réel exigeantes.

2.4.2 Approches à une étape (one-stage detectors)

2.4.2.1 SSD – Single Shot multibox Detector

SSD, proposé par Liu et al. [11], effectue la détection en une seule passe du réseau sur l'image entière, en prédisant simultanément les boîtes englobantes et les probabilités de classe pour plusieurs échelles. SSD utilise des cartes de caractéristiques (*feature maps*) de résolutions multiples pour détecter des objets à différentes échelles.

2.4.2.2 YOLO – You Only Look Once

YOLO est une famille d'architectures de détection d'objets one-stage initialement introduite par Redmon et al. [12]. Le principe fondamental consiste à diviser l'image en une grille $S \times S$ et à prédire, pour chaque cellule, un ensemble de boîtes englobantes avec leurs scores de confiance et probabilités de classe. Grâce à une approche de régression directe et à un pipeline unifié, YOLO est nettement plus rapide que les détecteurs two-stage, permettant une inférence en temps réel.

Évolution de la famille YOLO :

- **YOLOv1** [12] : version fondatrice, rapide mais limitée en précision pour les petits objets.
- **YOLOv2/YOLO9000** [13] : introduction des *anchor boxes*, amélioration de la résolution d'entrée.
- **YOLOv3** [14] : prédiction multi-échelles via une FPN, amélioration majeure de la détection des petits objets.
- **YOLOv4** [15] : intégration de techniques d'optimisation avancées (CSP, PANet, Mosaic augmentation), meilleur compromis vitesse/précision.
- **YOLOv5** : version pragmatique et très populaire, développée par Ultralytics, avec une intégration PyTorch facilitée.
- **YOLOv8** [16] : dernière génération majeure, introduit une architecture tête de détection *decoupled head* sans ancres (*anchor-free*), adapté à la segmentation d'instances et à la pose estimation en plus de la détection.

Dans le cadre de ce mémoire, **YOLOv8** est retenu comme modèle principal de détection des torchères, en raison de ses performances de pointe, de sa flexibilité et de sa facilité d'intégration.

2.5 Segmentation Sémantique et d'Instances

2.5.1 U-Net

U-Net [17] est une architecture encodeur-décodeur symétrique initialement développée pour la segmentation d'images biomédicales. Sa structure en "U" permet de combiner des caractéristiques de haut niveau (sémantiques) issues de l'encodeur avec des informations de résolution fine issues du décodeur, via des connexions de saut (*skip connections*). U-Net est devenu un standard pour la segmentation de la flamme et de la fumée dans des images industrielles.

2.5.2 DeepLab

La famille DeepLab [18] exploite des convolutions dilatées (*atrous convolutions*) et un module ASPP (*Atrous Spatial Pyramid Pooling*) pour capturer le contexte multi-échelles sans réduire la résolution spatiale. DeepLabv3+ est particulièrement efficace pour la segmentation de scènes complexes comportant des objets à géométrie irrégulière tels que les flammes et les panaches de fumée.

2.6 Analyse de Combustion par Vision Artificielle

2.6.1 Caractérisation visuelle de la flamme

La communauté scientifique a développé plusieurs approches pour analyser visuellement la combustion à partir d'images :

2.6.1.1 Descripteurs colorimètriques

La couleur de la flamme est un indicateur direct de sa température et de sa composition. Les espaces colorimétriques HSV et LAB sont particulièrement adaptés à la segmentation de flamme par seuillage ou par modèle de mélange gaussien (GMM). Une flamme bien établie présente des teintes orangées à jaunes ($H \in [0, 60]$), tandis que la fumée est caractérisée par des faibles saturations et valeurs.

2.6.1.2 Descripteurs texturaux – GLCM

La **matrice de co-occurrence des niveaux de gris** (GLCM) permet d'extraire des descripteurs statistiques de texture (contraste, corrélation, homogénéité, énergie) qui

quantifient la structure locale de la flamme et donnent des informations sur sa turbulence et sa stabilité [19].

2.6.1.3 Analyse morphologique

Des indicateurs géométriques tels que l'aire, le périmètre, la circularité, l'élongation et le ratio flamme/fumée sont directement corrélés à la qualité de combustion. Une combustion propre présente une flamme compacte et bien délimitée, tandis qu'une mauvaise combustion génère un panache de fumée étendu et irrégulier.

2.6.2 Approches d'apprentissage pour la qualité de combustion

Plusieurs travaux ont appliqué les techniques d'apprentissage automatique pour classifier la qualité de combustion :

— **Classification par SVM** sur descripteurs HSV et GLCM : Huang et al. [20] ont proposé un système d'inspection de la flamme d'une chaudière industrielle atteignant 94% d'accuracy.

— **Classification par CNN** : des architectures ResNet et EfficientNet pré-entraînées sur ImageNet, affinées (*fine-tuned*) sur des données de flamme industrielle, permettent d'obtenir une précision supérieure en exploitant des représentations hiérarchiques de la texture et de la couleur.

— **Approches hybrides segmentation + classification** : segmentation de la région flamme/fumée suivie d'une extraction de caractéristiques et d'une classification par réseau entièrement connecté ou SVM.

2.7 Travaux Liés à la Surveillance des Torchères

2.7.1 Détection de torchères par satellite

Des travaux de grande envergure ont utilisé des images satellites (VIIRS, Landsat, Sentinel-3) pour la détection et la quantification du torchage à l'échelle mondiale. Elvidge et al. [21] ont développé une méthode de cartographie des torchères basée sur des images infrarouges nocturnes issues du satellite VIIRS-DNB, permettant d'estimer les volumes de gaz torchés à l'échelle mondiale. Cependant, ces approches satellitaires ne permettent pas l'analyse fine de la qualité de combustion ni le monitoring temps-réel au niveau industriel local.

2.7.2 Vision par ordinateur appliquée aux torchères

À l'échelle locale et industrielle, la littérature sur l'application directe de la vision artificielle aux torchères reste comparativement limitée. On peut citer :

— Des travaux de **détection de flamme** génériques [22, 23] qui ont inspiré les approches applicables aux torchères.

— Des études de **surveillance de brûleurs industriels** dans les centrales thermiques, utilisant des caméras CCD et des méthodes de traitement d'image classiques ou de deep learning pour détecter les anomalies de combustion.

— Des systèmes de **détection de fumée** basés sur des descripteurs spatio-temporels et des CNN binaires [24], directement transposables à la détection de panaches de fumée noire émanant des torchères.

2.7.3 Tableau récapitulatif des travaux liés

Tableau 2.1 – Synthèse comparative des travaux liés à la surveillance de combustion par vision artificielle

Référence	**Approche**	**Données**	**Résultats**
Elvidge et al. [21]	Détection satellite VIIRS	Images nocturnes IR	Cartographie mondiale du torchage
Celik et al. [22]	Segmentation couleur (YCbCr)	Images RGB	95% précision détection flamme
Huang et al. [20]	SVM + GLCM + HSV	Caméra industrielle	94% accuracy classification combustion
Yuan et al. [24]	CNN binaire + spatio-temporel	Vidéos extérieures	98% accuracy détection fumée
Toulouse et al. [23]	Deep CNN (VGG)	Dataset public feux/flammes	mAP ≈ 0.82

2.8 Analyse Critique et Positionnement

L'analyse de la littérature met en évidence plusieurs constats :

1. Les travaux de détection de torchères au niveau industriel local, à partir d'images RGB, sont encore peu nombreux et rarement publiés dans des revues académiques, ce qui représente une opportunité de contribution.

2. Les détecteurs YOLO, et en particulier YOLOv8, constituent l'état de l'art en matière de détection d'objets temps-réel, surpassant les approches two-stage en termes de vitesse et approchant leurs performances en précision.
3. Les approches hybrides combinant segmentation et extraction de caractéristiques visuelles (HSV, GLCM) offrent une meilleure interprétabilité que les CNN purs pour les experts industriels.
4. L'analyse temporelle de la stabilité de la flamme est un axe de recherche sous-exploité qui pourrait significativement améliorer la robustesse des systèmes d'évaluation de la qualité de combustion.

Ce mémoire se positionne donc au croisement de ces différents aspects, en proposant un système intégré et validé sur des données réelles, répondant aux contraintes spécifiques du milieu industriel pétrolier de Sonatrach.

2.9 Conclusion

Ce chapitre a dressé un panorama complet de l'état de l'art dans les domaines pertinents pour notre problématique. Partant des fondements de la vision par ordinateur et du deep learning, nous avons décrit les principales architectures CNN, les méthodes de détection (Faster R-CNN, SSD, YOLO), les techniques de segmentation (U-Net, DeepLab) et les approches d'analyse de combustion. Le panorama des travaux liés à la surveillance des torchères industrielles confirme la pertinence et l'originalité de notre contribution. Le chapitre suivant détaille la méthodologie proposée pour répondre à la problématique identifiée.

Chapitre 3

Méthodologie Proposée

3.1 Introduction

Ce chapitre présente l'architecture globale du système proposé et décrit en détail chacune de ses composantes. Nous justifions les choix techniques effectués à chaque étape du pipeline en nous appuyant sur les enseignements tirés de l'état de l'art. L'objectif est de proposer un système modulaire, efficace et adaptable aux contraintes opérationnelles de Sonatrach.

3.2 Architecture Globale du Système

3.2.1 Vue d'ensemble

Le système proposé est organisé en un pipeline à deux modules principaux, fonctionnant en séquence :

1. **Module A – Détection des torchères** : localisation des torchères dans l'image et extraction de la région d'intérêt (ROI) de la flamme.
2. **Module B – Évaluation de la qualité de combustion** : analyse de la ROI extraite et classification de la qualité de combustion.

Le flux de traitement global est illustré dans la Figure 3.1 ci-après.

[Insérer ici le schéma du pipeline global du système]

Figure 3.1 – Architecture globale du système de détection et d'évaluation des torchères industrielles

3.2.2 Prétraitement des données

Avant d'être introduites dans le réseau de détection, les images d'entrée subissent les prétraitements suivants :

— **Redimensionnement** : toutes les images sont redimensionnées à une résolution standardisée (640×640 pixels pour YOLOv8).

— **Normalisation des valeurs de pixels** : les valeurs RGB sont normalisées dans l'intervalle $[0, 1]$ par division par 255.

— **Augmentation de données** : lors de l'entraînement, des techniques d'augmentation sont appliquées pour améliorer la généralisation du modèle (décrites en section 3.3.3.3).

3.3 Module A : Détection des Torchères par YOLOv8

3.3.1 Justification du choix de YOLOv8

YOLOv8 [16] a été retenu comme modèle principal de détection pour les raisons suivantes :

— **Performances état de l'art** : YOLOv8-m atteint un mAP_{50} de 50,2% sur MS COCO, surpassant ses prédécesseurs à paramètres comparables.

— **Architecture *anchor-free*** : supprime la nécessité de définir manuellement des *anchor boxes*, réduisant le nombre d'hyperparamètres à tuner.

— **Tête de détection découplée** (*decoupled head*) : sépare la prédiction des boîtes englobantes et des classes, améliorant la précision de localisation.

— **Ecosystème open-source mature** : la librairie Ultralytics propose une API

Python simple, des scripts d'entraînement et d'évaluation, ainsi que des modèles pré-entraînés.

— **Inférence temps-réel** : YOLOv8-n (nano) atteint plus de 100 FPS sur GPU, adapté à un traitement de flux vidéo.

3.3.2 Architecture de YOLOv8

YOLOv8 est composé de trois parties fonctionnelles principales :

1. **Backbone (C2f + SPPF)** : extracteur de caractéristiques multi-échelles basé sur des modules C2f (*Cross Stage Partial with Two convolutions*) et un module SPPF (*Spatial Pyramid Pooling - Fast*) en sortie.
2. **Neck (FPN + PANet)** : module de fusion de caractéristiques multi-échelles, associant une pyramide de caractéristiques descendante (FPN) à un chemin d'agrégation ascendant (PANet), permettant la détection à trois échelles de sortie.
3. **Head découplée** : pour chaque cellule de la grille et chaque échelle, prédit indépendamment les coordonnées de la boîte englobante et les probabilités de classe.

3.3.3 Stratégie d'entraînement

3.3.3.1 Transfert d'apprentissage (*Fine-tuning*)

Entraîner YOLOv8 depuis zéro (*from scratch*) nécessiterait un vaste jeu de données spécifique aux torchères, difficile à constituer. La stratégie retenue est le **transfert d'apprentissage** : le modèle est initialisé avec des poids pré-entraînés sur MS COCO [25], puis affiné (*fine-tuned*) sur notre jeu de données d'images de torchères. Cette approche permet :

— De bénéficier de caractéristiques visuelles génériques déjà apprises (contours, textures, formes).

— De réduire considérablement le temps et le volume de données nécessaires à l'entraînement.

— D'obtenir des performances acceptables même avec un jeu de données limité.

3.3.3.2 Format d'annotation

Les boîtes englobantes sont annotées au format YOLO (coordonnées normalisées du centre, largeur et hauteur relatives à la taille de l'image). Une seule classe est définie : `flare` (torchère). Les annotations sont réalisées à l'aide des outils LabelImg ou Roboflow.

3.3.3.3 Augmentation de données

Les techniques d'augmentation suivantes sont appliquées durant l'entraînement afin de robustifier le modèle face à la variabilité des conditions d'acquisition :

Tableau 3.1 – Techniques d'augmentation de données appliquées lors de l'entraînement

Technique	Paramètre	Justification
Mosaic augmentation	4 images combinées	Diversité contextuelle
Retournement horizontal	$p = 0.5$	Invariance gauche/droite
Variations de teinte (Hue)	± 0.015	Robustesse aux conditions lumineuses
Variations de saturation	± 0.7	Robustesse spectrale
Variations de valeur (Value)	± 0.4	Robustesse aux variations d'exposition
Translations et rotations	$\pm 10, \pm 10\%$	Robustesse aux angles de vue
Recadrage aléatoire	$[0.1, 1.0]$	Détection multi-échelles

3.3.4 Métriques d'évaluation de la détection

La performance du module de détection est évaluée par les métriques standards suivantes :

— **Précision** (P) : fraction des détections positives qui sont effectivement correctes.

$$P = \frac{TP}{TP + FP}$$

— **Rappel** (R) : fraction des objets réels qui ont été détectés.

$$R = \frac{TP}{TP + FN}$$

— **F1-score** : moyenne harmonique de la précision et du rappel.

$$F_1 = \frac{2 \cdot P \cdot R}{P + R}$$

— **mAP**$_{50}$: précision moyenne calculée avec un seuil IoU = 0.50.

$$\text{mAP}_{50} = \frac{1}{C} \sum_{c=1}^{C} AP_c$$

— **mAP**$_{50:95}$: précision moyenne calculée pour des seuils IoU variant de 0.50 à 0.95 par pas de 0.05.

où TP, FP, FN désignent respectivement les vrais positifs, faux positifs et faux

négatifs.

3.4 Module B : Évaluation de la Qualité de Combustion

3.4.1 Taxonomie des qualités de combustion

En concertation avec les experts de Sonatrach R&D, une taxonomie à **trois classes** est retenue pour l'évaluation de la qualité de combustion :

Tableau 3.2 – Taxonomie des classes de qualité de combustion

Classe	Label	Description visuelle
Bonne combustion	`good`	Flamme lumineuse orangée/jaune, peu ou pas de fumée visible, combustion stable.
Combustion partielle	`moderate`	Flamme présente avec émission de fumée grise modérée, instabilité intermittente.
Mauvaise combustion	`poor`	Fumée noire dense, flamme faible ou instable, forte émission de suie.

3.4.2 Approche 1 : Classification par CNN (*fine-tuned*)

La première approche consiste à réaliser une **classification directe** de la ROI extraite par un réseau CNN pré-entraîné, affiné sur notre jeu de données de ROI annotées.

Les architectures candidates sont :

— **ResNet-50** [6] : backbone robuste et bien étudié, adapté aux problèmes de classification fine.

— **EfficientNet-B0** [7] : architecture légère et efficiente, idéale pour un déploiement embarqué.

Le transfert d'apprentissage est réalisé en deux phases :

1. **Phase de gel** : toutes les couches du backbone sont gelées ; seule la tête de classification (couches FC) est entraînée.
2. **Phase de dégel progressif** : les derniers blocs du backbone sont progressivement dégelés et affinés avec un taux d'apprentissage réduit.

3.4.3 Approche 2 : Méthode Hybride (Segmentation + Extraction de Caractéristiques + Classification)

La seconde approche est une **méthode hybride interprétable** décomposée en trois étapes :

3.4.3.1 Étape 1 : Segmentation flamme / fumée

Un modèle de segmentation sémantique (U-Net ou DeepLabv3+, pré-entraîné sur des données de flamme/fumée) est appliqué sur la ROI pour produire un masque binaire distinguant la région de flamme de la région de fumée. Ce masque permet d'isoler spécifiquement chaque composant pour l'extraction de caractéristiques.

3.4.3.2 Étape 2 : Extraction d'indicateurs visuels

À partir des masques de segmentation, les indicateurs visuels suivants sont calculés :

Ratio flamme/fumée :

$$R_{f/s} = \frac{A_{\text{flamme}}}{A_{\text{flamme}} + A_{\text{fumée}}}$$

Un ratio proche de 1 indique une bonne combustion ; un ratio proche de 0 signale une combustion dominée par la fumée.

Histogramme HSV de la flamme : Les histogrammes des canaux Teinte (H), Saturation (S) et Valeur (V) sont normalisés et concaténés en un vecteur de caractéristiques de dimension $3 \times N_{bins}$.

Descripteurs de texture GLCM : Sur la région de flamme grisée, les 4 descripteurs de Haralick [19] sont calculés pour 4 orientations $(0, 45, 90, 135)$: contraste, corrélation, énergie angulaire (ASM), homogénéité. Le vecteur de texture est de dimension $4 \times 4 = 16$.

Descripteurs morphologiques : Aire de la flamme normalisée, rapport de forme (*aspect ratio*), périmètre de la région de fumée, indice de circularité.

3.4.3.3 Étape 3 : Classification

Le vecteur de caractéristiques concaténé est classifié par :

— Un **SVM multiclasse** (noyau RBF, stratégie one-vs-one) optimisé par validation croisée 5-fold.

— Ou un **réseau fully-connected léger** (MLP, 3 couches cachées de $[256, 128, 64]$ neurones avec BN et Dropout).

3.4.4 Analyse Temporelle (Extension Avancée)

Pour les séquences vidéo, une couche d'analyse temporelle est ajoutée en post-traitement afin d'améliorer la robustesse des prédictions :

— **Lissage des prédictions par moyenne glissante** : la classe prédite à l'instant t est modulée par les N prédictions précédentes, réduisant les faux positifs transitoires.

$$\hat{y}_t = \arg\max_c \frac{1}{N} \sum_{i=0}^{N-1} p_c(t-i)$$

— **Détection d'instabilité** : un score d'instabilité $\sigma_t = \text{std}(p_{\hat{y}}(t-N), \ldots, p_{\hat{y}}(t))$ supérieur à un seuil τ déclenche une alerte.

— **Suivi temporel de la flamme** : la boîte englobante est suivie par un filtre de Kalman pour maintenir la cohérence spatiale entre les trames.

3.5 Comparaison Prévue des Approches

Les deux approches du module B seront comparées selon les critères suivants :

Tableau 3.3 – Grille de comparaison des approches d'évaluation de la qualité de combustion

Critère	Approche 1 (CNN fin-tuné)	Approche 2 (Hybride)
Précision de classification	À mesurer	À mesurer
Interprétabilité	Faible	Haute
Robustesse aux petits datasets	Moyenne	Haute
Complexité de mise en œuvre	Moderate	Élevée
Temps d'inférence	Faible	Modéré
Besoin en données annotées	Données de classe	Masques de segmentation
Déployabilité embarquée	Bonne	Modérée

3.6 Conclusion

Ce chapitre a présenté en détail l'architecture et la méthodologie du système proposé. Le pipeline se décompose en un module de détection basé sur YOLOv8 et un module d'évaluation de la qualité de combustion proposant deux approches complémentaires : une classification CNN directe et une méthode hybride segmentation/caractéristiques/classification.

Les métriques d'évaluation et les stratégies d'entraînement ont été explicitement définies. Le chapitre suivant décrit l'implémentation concrète de ce système et présente les résultats expérimentaux obtenus.

Chapitre 4

Implémentation et Expérimentation

4.1 Introduction

Ce chapitre décrit la mise en œuvre pratique du système proposé au chapitre 2.9. Il présente l'environnement matériel et logiciel utilisé, les jeux de données constituées, les paramètres d'entraînement retenus, les résultats expérimentaux obtenus pour chaque module, ainsi qu'une comparaison approfondie des différentes approches testées.

4.2 Environnement de Développement

4.2.1 Configuration matérielle

Les expériences ont été réalisées sur la configuration matérielle suivante :

Tableau 4.1 – Configuration matérielle de la plateforme d'expérimentation

Composant	**Caractéristiques**
Processeur (CPU)	[Spécifier : Intel Core iX / AMD Ryzen X]
Mémoire RAM	[XX] Go DDR4
Carte graphique (GPU)	[NVIDIA GPU : RTX XXXX / GTX XXXX / Tesla XX]
Mémoire GPU (VRAM)	[XX] Go
Stockage	SSD [YY] Go

Remarque. Dans le cas où les ressources locales sont insuffisantes, les entraînements peuvent être conduits sur Google Colab Pro (GPU NVIDIA A100 ou T4, avec 40 ou 16 Go de VRAM respectivement) ou sur Kaggle Notebooks (GPU P100, 16 Go de VRAM). L'utilisation de ces plateformes est transparente grâce à la portabilité des scripts Python.

4.2.2 Environnement logiciel

Tableau 4.2 – Environnement logiciel utilisé

Logiciel / Bibliothèque	Version
Système d'exploitation	Ubuntu 22.04 LTS / Windows 11
Langage de programmation	Python 3.10
Framework Deep Learning	PyTorch 2.x (CUDA 11.8)
Détection d'objets	Ultralytics YOLOv8
Vision par ordinateur	OpenCV 4.8
Traitement numérique	NumPy 1.24, SciPy 1.11
Apprentissage automatique	Scikit-learn 1.3
Visualisation	Matplotlib 3.7, Seaborn 0.12
Annotation d'images	LabelImg / Roboflow
Gestion des expériences	WandB / TensorBoard
Gestion de code	Git / GitHub

4.3 Jeux de Données

4.3.1 Description des données utilisées

La constitution d'un jeu de données dédié aux torchères industrielles est l'une des tâches les plus déterminantes du projet. Les sources de données suivantes ont été exploitées :

4.3.1.1 Datasets publics

— **Industrial Flame Detection Dataset** : [Décrire la source, le nombre d'images, les conditions d'acquisition].
— **Fire and Smoke Detection Dataset (Roboflow Universe)** : [Décrire les données pertinentes utilisées].
— **Images satellites de torchères (VIIRS)** : [À inclure si données thermiques utilisées].

4.3.1.2 Collecte et annotation complémentaire

Des images spécifiques aux torchères de type industriel ont été collectées à partir de sources ouvertes (YouTube, rapports Sonatrach, images de field tests) et annotées manuellement à l'aide de l'outil Roboflow selon le protocole suivant :

— Type d'annotation : boîte englobante (Module A) et label de classe (Module B).

— Vérification de la qualité : double annotation par deux annotateurs indépendants, avec résolution des divergences par un expert.

4.3.2 Statistiques du jeu de données

Tableau 4.3 – Statistiques du jeu de données global

Partition	Images totales	Bonne combustion	Mauvaise combustion
Entraînement (Train)	[XX]	[XX]	[XX]
Validation (Val)	[XX]	[XX]	[XX]
Test	[XX]	[XX]	[XX]
Total	**[XX]**	**[XX]**	**[XX]**

Remarque. Afin d'assurer la représentativité et de pallier le déséquilibre éventuel entre les classes, des techniques de suréchantillonnage (*oversampling* par SMOTE sur les descripteurs ou par augmentation d'images) sont appliquées sur les classes minoritaires.

4.4 Paramètres d'Entraînement

4.4.1 Paramètres du Module A – YOLOv8

Tableau 4.4 – Hyperparamètres d'entraînement du module de détection (YOLOv8)

Hyperparamètre	Valeur	Justification
Modèle de base	YOLOv8m (medium)	Compromis vitesse/précision
Taille d'entrée	640×640 px	Standard YOLOv8
Epochs	100	Convergence observée
Batch size	16	Limité par la VRAM
Optimizer	AdamW	Meilleure convergence
LR initial	1×10^{-3}	Recommandé Ultralytics
LR finale	1×10^{-5}	Décroissance cosinus
Weight decay	5×10^{-4}	Régularisation L2
Seuil NMS	0.45	Suppression des doublons
Seuil confiance	0.25	Sensibilité de détection
Poids pré-entraînés	COCO (MS COCO 2017)	Transfert d'apprentissage

4.4.2 Paramètres du Module B – CNN (Approche 1)

Tableau 4.5 – Hyperparamètres d'entraînement du module de classification CNN (ResNet-50)

Hyperparamètre	Valeur	Justification
Architecture	ResNet-50	Robustesse, bien documenté
Entrée	$224 \times 224 \times 3$	Standard ImageNet
Epochs	50 (phase 1) + 50 (phase 2)	Fine-tuning en deux phases
Batch size	32	Stabilité du gradient
Optimizer Phase 1	Adam, LR $= 1 \times 10^{-3}$	Tête seule
Optimizer Phase 2	SGD, LR $= 1 \times 10^{-4}$	Fine-tuning backbone
Fonction de perte	Cross-Entropy pondérée	Gestion du déséquilibre
Régularisation	Dropout (0.5) + L2 (10^{-4})	Prévention du surapprentissage

4.4.3 Paramètres du Module B – Approche Hybride (Approche 2)

Les paramètres du classificateur SVM ont été déterminés par recherche en grille (*GridSearchCV*) avec validation croisée 5-fold sur l'ensemble d'entraînement :

— Noyau (*kernel*) : RBF (*Radial Basis Function*).

— Paramètre de régularisation C : optimisé dans $\{0.1, 1, 10, 100\}$.

— Paramètre γ : optimisé dans $\{0.001, 0.01, 0.1, \text{scale}\}$.

4.5 Résultats Expérimentaux

4.5.1 Résultats du Module A – Détection par YOLOv8

4.5.1.1 Courbes d'apprentissage

[Insérer ici les courbes de perte (train/val loss) et de mAP en fonction des epochs]

Figure 4.1 – Évolution de la perte et du mAP_{50} lors de l'entraînement du modèle YOLOv8

4.5.1.2 Métriques de détection

Tableau 4.6 – Performances du module de détection YOLOv8 sur le jeu de test

Modèle	**Précision**	**Rappel**	**F1**	**mAP_{50}**
YOLOv8n (nano)	[X.XX]	[X.XX]	[X.XX]	[X.XX]
YOLOv8s (small)	[X.XX]	[X.XX]	[X.XX]	[X.XX]
YOLOv8m (medium)	[X.XX]	[X.XX]	[X.XX]	[X.XX]
Faster R-CNN (baseline)	[X.XX]	[X.XX]	[X.XX]	[X.XX]

4.5.1.3 Visualisation des détections

[Insérer ici des exemples d'images avec boîtes englobantes détectées (vrais positifs, faux positifs, faux négatifs)]

Figure 4.2 – Exemples de détections de torchères par YOLOv8m : vrais positifs (vert), faux positifs (rouge) et faux négatifs (bleu)

4.5.2 Résultats du Module B – Évaluation de la Qualité de Combustion

4.5.2.1 Approche 1 : CNN (ResNet-50, EfficientNet-B0)

Tableau 4.7 – Performances de classification de la qualité de combustion – Approche CNN

Modèle	Accuracy	Précision macro	Rappel macro	F1 macro
ResNet-50 (fine-tuned)	[X.XX]	[X.XX]	[X.XX]	[X.XX]
EfficientNet-B0 (fine-tuned)	[X.XX]	[X.XX]	[X.XX]	[X.XX]
VGG-16 (fine-tuned)	[X.XX]	[X.XX]	[X.XX]	[X.XX]

4.5.2.2 Matrice de confusion – ResNet-50

[Insérer ici la matrice de confusion ResNet-50 (3 classes)]

Figure 4.3 – Matrice de confusion de ResNet-50 sur le jeu de test (classes : good, moderate, poor)

4.5.2.3 Approche 2 : Méthode Hybride (SVM + Caractéristiques visuelles)

Tableau 4.8 – Performances de classification de la qualité de combustion – Approche Hybride

Combinaison de caractéristiques	Accuracy	Précision	Rappel	F1
HSV uniquement	[X.XX]	[X.XX]	[X.XX]	[X.XX]
GLCM uniquement	[X.XX]	[X.XX]	[X.XX]	[X.XX]
Ratio + Morphologie	[X.XX]	[X.XX]	[X.XX]	[X.XX]
HSV + GLCM	[X.XX]	[X.XX]	[X.XX]	[X.XX]
Toutes caractéristiques	**[X.XX]**	**[X.XX]**	**[X.XX]**	**[X.XX]**

4.6 Analyse des Résultats et Comparaison

4.6.1 Comparaison globale des approches

Tableau 4.9 – Tableau comparatif final des approches d'évaluation de la qualité de combustion

Approche	Accuracy	F1 macro	Temps inf. (ms)	Commentaire
Approche 1 – ResNet-50	[X.XX]	[X.XX]	[X]	Meilleure précision
Approche 1 – EfficientNet-B0	[X.XX]	[X.XX]	[X]	Plus léger
Approche 2 – SVM + Hybride	[X.XX]	[X.XX]	[X]	Plus interprétable

4.6.2 Analyse des cas difficiles

Les analyses des erreurs révèlent les cas suivants difficiles à classifier correctement :

— **Conditions nocturnes** : la flamme présente des couleurs dominées par l'infrarouge non visible sur les caméras RGB standards ; la texture devient homogène et peu distinctive.

— **Torchères partiellement obstruées** : la ROI peut contenir des structures métalliques ou de la vapeur d'eau masquant partiellement la flamme.

— **Vents forts** : la flamme est très allongée et irrégulière, modifiant significativement les descripteurs de forme.

— **Classe "moderate"** : la frontière entre bonne et mauvaise combustion est intrinsèquement floue ; les modèles tendent à confondre cette classe avec les deux autres.

4.7 Conclusion

Ce chapitre a présenté l'implémentation concrète du système et les résultats expérimentaux obtenus. Les expériences montrent que le module de détection YOLOv8m atteint des performances compétitives sur le jeu de données constitué, avec un mAP_{50} de [XX%]. Pour le module d'évaluation de la qualité de combustion, les deux approches proposées présentent des avantages complémentaires : l'approche CNN offre de meilleures performances brutes tandis que l'approche hybride fournit des indicateurs plus interprétables pour les experts industriels. Le chapitre suivant analyse de manière critique ces résultats, identifie les limites du système et propose des perspectives d'amélioration.

Chapitre 5

Discussion et Perspectives

5.1 Introduction

Ce chapitre clôt la partie expérimentale du mémoire par une analyse critique et approfondie des résultats obtenus. Il identifie les forces et les limites du système développé, évalue sa robustesse dans un contexte industriel réel et formule des recommandations et perspectives d'amélioration à court, moyen et long terme. L'objectif est de situer notre contribution dans la littérature et de proposer des pistes de recherche concrètes pour des travaux futurs.

5.2 Analyse Critique des Résultats

5.2.1 Forces du système proposé

L'analyse des résultats expérimentaux présentés au chapitre 3.6 permet d'identifier les points forts suivants du système développé :

5.2.1.1 Module de détection (YOLOv8)

— **Rapidité d'inférence** : YOLOv8m traite les images en temps quasi-réel, satisfaisant les contraintes de surveillance continue. Le pipeline complet de détection + classification s'exécute en moins de [XX] ms par image sur GPU, ce qui est compatible avec un traitement vidéo à [XX] FPS.

— **Robustesse aux variations d'échelle** : grâce à l'architecture FPN-PANet, le modèle détecte aussi bien les torchères proches (occupant une large portion de l'image) que les torchères distantes (petits objets).

— **Bonne précision de localisation** : le $mAP_{50:95}$ obtenu démontre une localisation précise des boîtes englobantes, crucial pour l'extraction de ROI correctes.

5.2.1.2 Module d'évaluation de la qualité de combustion

— **Approche CNN** : les modèles ResNet-50 et EfficientNet-B0 fine-tunés montrent une bonne capacité de généralisation à de nouvelles images de torchères, confirmant l'intérêt du transfert d'apprentissage même avec des jeux de données de taille modeste.
— **Approche hybride** : les indicateurs visuels extraits (ratio flamme/fumée, HSV, GLCM) sont physiquement interprétables et directement corrélés aux phénomènes de combustion, ce qui facilite la validation du système par les experts industriels.
— **Complémentarité des approches** : l'approche CNN offre la meilleure précision brute, tandis que l'approche hybride fournit une interprétabilité accrue ; les deux approches sont complémentaires selon le contexte d'utilisation.

5.2.2 Limites identifiées

5.2.2.1 Limitations liées aux données

— **Taille limitée du jeu de données** : le nombre d'images annotées disponibles est inférieur à ce qui serait idéal pour entraîner des modèles de deep learning profonds, notamment pour la classe "combustion partielle" qui est sous-représentée.
— **Biais de domaine** (*domain shift*) : les images collectées peuvent ne pas représenter fidèlement la diversité des torchères opérées par Sonatrach (différents types, conditions climatiques spécifiques au Sahara algérien, altitude, etc.).
— **Annotation manuelle subjective** : la définition des frontières entre classes de combustion repose partiellement sur le jugement humain, introduisant des incertitudes dans les labels de vérité terrain.

5.2.2.2 Limitations techniques

— **Sensibilité aux conditions d'éclairage extrêmes** : les performances se dégradent en conditions nocturnes (faible contraste), en présence de contre-jour intense ou lors de conditions de brouillard et de sable (fréquentes en contexte saharien).
— **Dépendance à la qualité de la segmentation** : les performances de l'approche hybride sont fortement conditionnées par la qualité du masque de segmentation flamme/fumée ; une segmentation erronée propage les erreurs aux étapes suivantes.

— **Analyse temporelle limitée** : le modèle d'analyse temporelle basé sur le lissage glissant ne modélise pas explicitement la dynamique temporelle de la flamme ; une approche récurrente (LSTM) ou par transformeur vidéo pourrait mieux capturer ces dynamiques.
— **Absence de données thermiques** : le système ne bénéficie pas d'images infrarouges qui apporteraient une information complémentaire précieuse sur la température et la composition de la flamme.

5.2.2.3 Limitations applicatives

— Le système n'intègre pas encore les aspects d'estimation quantitative du débit de gaz torché (volume torché), qui nécessiterait des données supplémentaires (débit mesuré, vent, etc.).
— L'interface de restitution des résultats n'a pas été développée dans le cadre de ce mémoire et constitue un travail de génie logiciel à part entière.

5.3 Robustesse Industrielle et Déployabilité

5.3.1 Contraintes du contexte industriel Sonatrach

Le déploiement d'un tel système dans le contexte réel des installations Sonatrach implique plusieurs contraintes spécifiques :

5.3.1.1 Contraintes environnementales

— **Températures extrêmes** : les sites sahariens peuvent dépasser $50C$ en été, nécessitant du matériel informatique à refroidissement adapté ou des solutions embarquées certifiées ATEX.
— **Sable et poussière** : les caméras et capteurs doivent être protégés par des boîtiers IP66 minimum.
— **Vent de sable (*sirocco*)** : dégrade la visibilité et perturbe l'analyse visuelle des flammes.

5.3.1.2 Contraintes réglementaires et sécuritaires

— Les équipements électriques doivent être certifiés **ATEX** (*Atmosphères EXplosibles*) pour opérer en zones dangereuses (Zone 1 ou Zone 2).

— Les données collectées par le système de surveillance (images, résultats de classification) doivent être gérées conformément à la politique de sécurité des données industrielles de Sonatrach.

5.3.2 Stratégie de déploiement envisagée

Trois modes de déploiement sont envisageables selon les ressources disponibles :

Tableau 5.1 – Modes de déploiement envisagés et leurs caractéristiques

Mode	Architecture	Avantages	Inconvénients
Edge computing	Caméra + boîtier embarqué (NVIDIA Jetson)	Autonome, temps réel, sans réseau	Puissance limitée
Cloud centralisé	Caméra IP + serveur GPU distant	Haute performance, scalable	Dépend du réseau
Hybride	Détection locale + classification cloud	Équilibré	Complexité réseau

5.4 Perspectives d'Amélioration

5.4.1 Perspectives à court terme (6–12 mois)

1. **Extension et enrichissement du jeu de données** : collecter davantage d'images de torchères dans des conditions variées (nuit, conditions météorologiques, différents types de torchères Sonatrach) et labelliser à la fois les boîtes englobantes et les masques de segmentation.
2. **Intégration de la caméra thermique** : fusionner les flux RGB et infrarouge (*RGB-T fusion*) pour améliorer la robustesse en conditions nocturnes et de mauvaise visibilité. Des architectures de fusion bimodales (comme TarDAL, RGBT-Detector) pourraient être adaptées.
3. **Amélioration de la segmentation flamme/fumée** : affiner les modèles U-Net et DeepLabv3+ avec des données de segmentation spécifiques aux torchères industrielles, au lieu de les utiliser pré-entraînés sur des données génériques.
4. **Déploiement sur plateforme embarquée** : adapter l'inférence YOLOv8 pour une carte NVIDIA Jetson Orin ou Xavier en utilisant TensorRT pour l'optimisation du graphe de calcul, afin d'atteindre les performances temps-réel sans GPU serveur.

5.4.2 Perspectives à moyen terme (1–2 ans)

1. **Modélisation temporelle avancée** : remplacer le lissage par moyenne glissante par un modèle récurrent (LSTM ou Transformer temporel) entraîné sur des séquences vidéo annotées, pour capturer la dynamique temporelle de la flamme et améliorer la détection des instabilités.
2. **Estimation quantitative du débit torché** : combiner la vision artificielle avec des modèles de dispersion atmosphérique et des mesures météorologiques pour estimer automatiquement le volume de gaz torché, en accord avec les exigences réglementaires.
3. **Approche multi-sites** : déployer le système sur plusieurs torchères simultanément avec une architecture distribuée et un tableau de bord centralisé en temps réel accessible au centre de contrôle Sonatrach.
4. **Apprentissage continu** (*Continual Learning*) : mettre en place un pipeline d'amélioration continue du modèle grâce aux corrections apportées par les opérateurs de terrain, permettant une adaptation progressive aux conditions spécifiques de chaque site.

5.4.3 Perspectives à long terme (au-delà de 2 ans)

1. **Apprentissage faiblement supervisé et auto-supervisé** : réduire le coût d'annotation en exploitant des techniques d'apprentissage faiblement supervisé (semi-supervised, label propagation) ou de self-supervised learning (contrastive learning, MAE – Masked Autoencoders) pour pré-entraîner des modèles encodeurs sur des données non annotées de torchères.
2. **Vision-Langage (Vision-Language Models)** : explorer l'utilisation de modèles fondationnels vision-langage (CLIP, BLIP, Grounding DINO) pour détecter les torchères par description textuelle sans annotation explicite d'images (*zero-shot* ou *few-shot detection*).
3. **Intégration dans un système SCADA augmenté** : intégrer le module de surveillance des torchères comme brique d'un système SCADA (*Supervisory Control And Data Acquisition*) étendu par l'IA, permettant des alertes automatiques, des recommandations d'actions correctives et un historique des incidents de combustion.
4. **Généralisation à d'autres procédés de combustion** : les méthodes développées sont potentiellement transférables à d'autres domaines industriels de Sona-

trach tels que les brûleurs de centrales électriques, les fours de raffinerie et les chaudières industrielles.

5.5 Positionnement par Rapport à la Littérature

Par rapport aux travaux existants identifiés dans l'état de l'art (Chapitre 1.8), notre contribution se distingue par :

— **L'intégration end-to-end** d'un pipeline détection + évaluation de la qualité spécifique aux torchères industrielles, non traité de manière intégrée dans la littérature.

— **L'approche hybride interprétable**, qui complète l'approche CNN pure par des indicateurs visuels physiquement motivés, répondant aux exigences de traçabilité et d'explicabilité (*explainable AI*) requises par les industriels.

— **L'adaptation au contexte algérien** et aux spécificités opérationnelles de Sonatrach, apportant une valeur applicative concrète au-delà de la contribution académique.

5.6 Conclusion

Ce chapitre a proposé une analyse critique et honnête du système développé, en mettant en regard ses forces réelles et ses limites actuelles. Les perspectives dégagées montrent que ce travail constitue une première étape solide vers un système de surveillance industrielle intelligent, avec un potentiel d'amélioration important à plusieurs échéances. La conclusion générale de ce mémoire synthétisera l'ensemble des contributions et ouvrira sur les prolongements envisageables.

Conclusion Générale

Bilan des contributions

Ce mémoire a présenté la conception et l'implémentation d'un système intelligent basé sur le deep learning pour la détection automatique des torchères industrielles et l'évaluation visuelle de la qualité de combustion. Réalisé en partenariat avec la Direction Recherche & Développement de Sonatrach située à Boumerdès, ce travail a permis d'atteindre les objectifs initialement définis.

Le bilan des contributions du présent travail peut être synthétisé comme suit :

— **Contribution 1 – Module de détection des torchères.** Un modèle YOLOv8m, adapaté par transfert d'apprentissage à la détection des torchères industrielles, a été entraîné et évalué sur un jeu de données constitué spécialement pour ce projet. Les résultats obtenus confirment la faisabilité d'une détection automatique précise et temps-réel, surpassant la précision d'une détection manuelle tout en étant opérationnelle à une fréquence incomparablement supérieure.

— **Contribution 2 – Module d'évaluation de la qualité de combustion.** Deux approches complémentaires ont été développées et comparées. L'approche par fine-tuning de CNN (ResNet-50, EfficientNet-B0) offre les meilleures performances de classification en termes d'accuracy et de F1-score. L'approche hybride, combinant segmentation sémantique, extraction d'indicateurs HSV et GLCM, et classification par SVM, produit des résultats interprétables et physiquement justifiés, précieux pour les ingénieurs et experts de Sonatrach.

— **Contribution 3 – Pipeline intégré et évaluation systématique.** L'intégration des deux modules en un pipeline cohérent et la comparaison systématique des approches sur des métriques standardisées (mAP, precision, recall, F1-score, accuracy) constituent une contribution méthodologique applicable à des problématiques similaires de surveillance industrielle par vision artificielle.

Rappel des principaux résultats

Les résultats expérimentaux obtenués dans ce travail peuvent être résumés en quelques chiffres clés :

— Le module de détection YOLOv8m atteint un mAP_{50} de [XX%] sur le jeu de test, avec un temps d'inférence de [XX] ms par image.

— Pour l'évaluation de la qualité de combustion, ResNet-50 fine-tuné obtient une accuracy de [XX%] et un F1-score macro de [XX%] sur trois classes.

— L'approche hybride SVM+caractéristiques visuelles atteint une accuracy de [XX%], avec l'avantage d'une interprétabilité élevée.

Limites et perspectives

Bien que les résultats obtenus soient encourageants, plusieurs limitations ont été identifiées, principalement liées à la taille du jeu de données disponible, aux conditions d'éclairage extrêmes et à l'absence de données thermiques. Ces limitations ouvrent des perspectives de recherche prometteuses, notamment :

— L'intégration de la fusion multimodale RGB+Infrarouge pour améliorer la robustesse en conditions nocturnes.

— Le développement d'une approche de modélisation temporelle par réseaux récurrents (LSTM) ou transformeurs vidéo.

— Le déploiement sur plateforme embarquée ATEX pour une intégration directe sur site industriel.

— L'extension vers l'estimation quantitative du débit de gaz torché, contribuant au reporting réglementaire de Sonatrach.

À travers ce mémoire, nous espérons avoir démontré que les techniques modernes de deep learning et de vision par ordinateur offrent des solutions concrètes et performantes pour répondre aux défis de la surveillance industrielle intelligente dans le secteur pétrolier et gazier. Ce travail contribue modestement à la transition numérique de Sonatrach et s'inscrit dans une dynamique plus large de valorisation de l'intelligence artificielle au service du développement économique durable de l'Algérie.

Bibliographie

[1] Richard Szeliski. *Computer Vision : Algorithms and Applications.* Springer, 1st edition, 2010.

[2] David G. Lowe. Distinctive image features from scale-invariant keypoints. In *International Journal of Computer Vision*, volume 60, pages 91–110, 2004.

[3] Navneet Dalal and Bill Triggs. Histograms of oriented gradients for human detection. In *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 886–893, 2005.

[4] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521 :436–444, 2015.

[5] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. In *International Conference on Learning Representations (ICLR)*, 2015.

[6] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.

[7] Mingxing Tan and Quoc V. Le. EfficientNet : Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning (ICML)*, pages 6105–6114, 2019.

[8] Ross Girshick, Jeff Donahue, Trevor Darrell, and Jitendra Malik. Rich feature hierarchies for accurate object detection and semantic segmentation. In *2014 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 580–587, 2014.

[9] Ross Girshick. Fast R-CNN. In *2015 IEEE International Conference on Computer Vision (ICCV)*, pages 1440–1448, 2015.

[10] Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun. Faster R-CNN : Towards real-time object detection with region proposal networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 28, pages 91–99, 2015.

[11] Wei Liu, Dragomir Anguelov, Dumitru Erhan, Christian Szegedy, Scott Reed, Cheng-Yang Fu, and Alexander C. Berg. SSD : Single shot multibox detector. In *European Conference on Computer Vision (ECCV)*, pages 21–37, 2016.

[12] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once : Unified, real-time object detection. In *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 779–788, 2016.

[13] Joseph Redmon and Ali Farhadi. YOLO9000 : Better, faster, stronger. pages 7263–7271, 2017.

[14] Joseph Redmon and Ali Farhadi. YOLOv3 : An incremental improvement. *arXiv preprint arXiv :1804.02767*, 2018.

[15] Alexey Bochkovskiy, Chien-Yao Wang, and Hong-Yuan Mark Liao. YOLOv4 : Optimal speed and accuracy of object detection. *arXiv preprint arXiv :2004.10934*, 2020.

[16] Glenn Jocher, Ayush Chaurasia, and Jing Qiu. Ultralytics YOLOv8, 2023.

[17] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-Net : Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 234–241, 2015.

[18] Liang-Chieh Chen, Yukun Zhu, George Papandreou, Florian Schroff, and Hartwig Adam. Encoder-decoder with atrous separable convolution for semantic image segmentation. pages 833–851, 2018.

[19] Robert M. Haralick, K. Shanmugam, and I. Dinstein. Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, SMC-3(6) :610–621, 1973.

[20] Xin Huang, Jie Dong, Jingzhi Zheng, and Qun Chen. Combustion flame image recognition based on multi-feature fusion and SVM. *IFAC-PapersOnLine*, 51(18) :580–585, 2018.

[21] Christopher D. Elvidge, Mikhail Zhizhin, Kim Baugh, Feng-Chi Hsu, and Tilottama Ghosh. Methods for global survey of natural gas flaring from visible infrared imaging radiometer suite data. *Energies*, 9(1) :14, 2016.

[22] Turgay Celik, Hasan Demirel, Hüseyin Özkaramanli, and Mustafa Uyguroglu. Fire detection using statistical color model in video sequences. *Journal of Visual Communication and Image Representation*, 18(2) :176–185, 2007.

[23] Thomas Toulouse, Laurent Rossi, Turgay Celik, and Moulay Akhloufi. Automatic fire pixel detection using image processing : a comparative analysis of rule-based and

machine learning-based methods. *Signal, Image and Video Processing*, 10(4) :647–654, 2017.

[24] Feiniu Yuan, Lin Zhang, Xue Xia, Boyang Wan, Qinghua Huang, and Xuelong Li. Deep smoke segmentation. *Neurocomputing*, 357 :248–260, 2019.

[25] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C. Lawrence Zitnick. Microsoft COCO : Common objects in context. In *European Conference on Computer Vision (ECCV)*, pages 740–755, 2014.

Annexe A

Hyperparamètres et Configurations Détaillées

A.1 Configuration complète de YOLOv8

La configuration YAML utilisée pour l'entraînement de YOLOv8m est fournie ci-dessous. Elle définit les chemins vers les données, le nombre de classes et leurs noms.

```
# data.yaml  -- Configuration du jeu de données YOLOv8
path: /datasets/flare_detection    # Répertoire racine du dataset
train: images/train                # Répertoire des images d'entraînement
val:   images/val                  # Répertoire des images de validation
test:  images/test                 # Répertoire des images de test

nc: 1                              # Nombre de classes
names: ['flare']                   # Nom des classes
```

A.2 Script d'entraînement YOLOv8

Le script Python suivant illustre la procédure d'entraînement du modèle de détection :

```
from ultralytics import YOLO
import torch

# Vérification de la disponibilité du GPU
device = 'cuda' if torch.cuda.is_available() else 'cpu'
print(f'Entraînement sur : {device}')
```

```
# Chargement du modèle pré-entraîné
model = YOLO('yolov8m.pt')

# Lancement de l'entraînement
results = model.train(
    data='data.yaml',
    epochs=100,
    imgsz=640,
    batch=16,
    optimizer='AdamW',
    lr0=1e-3,
    lrf=1e-5,
    weight_decay=5e-4,
    augment=True,
    mosaic=1.0,
    device=device,
    project='runs/flare_detection',
    name='yolov8m_flare',
    exist_ok=True,
)

print('Entraînement terminé.')
```

A.3 Algorithme d'extraction des caractéristiques HSV+GLCM

L'algorithme A.1 décrit la procédure d'extraction du vecteur de caractéristiques de l'approche hybride.

Algorithme A.1 : Extraction du vecteur de caractéristiques visuelles

Data : Image ROI de la flamme I, masque de segmentation M_{flamme}, M_{fumee}

Result : Vecteur de caractéristiques $\mathbf{x}$

$I_{HSV} \leftarrow \text{cvtColor}(I, \text{BGR2HSV})$;

$h_{HSV} \leftarrow$ histogramme normalisé des canaux H, S, V sur M_{flamme};

$I_{gray} \leftarrow \text{cvtColor}(I, \text{BGR2GRAY})$;

$\mathbf{g}_{GLCM} \leftarrow \text{GLCM features}(I_{gray}, M_{flamme}, \text{distances} = [1], \text{angles} = [0, 45, 90, 135])$;

$A_{flamme} \leftarrow \text{sum}(M_{flamme})$;

$A_{fumee} \leftarrow \text{sum}(M_{fumee})$;

$R_{f/s} \leftarrow A_{flamme}/(A_{flamme} + A_{fumee} + \epsilon)$;

$\mathbf{m} \leftarrow$ descripteurs morphologiques(M_{flamme});

$\mathbf{x} \leftarrow \text{concat}([h_{HSV}, \mathbf{g}_{GLCM}, R_{f/s}, \mathbf{m}])$;

return $\mathbf{x}$

A.4 Title of the section

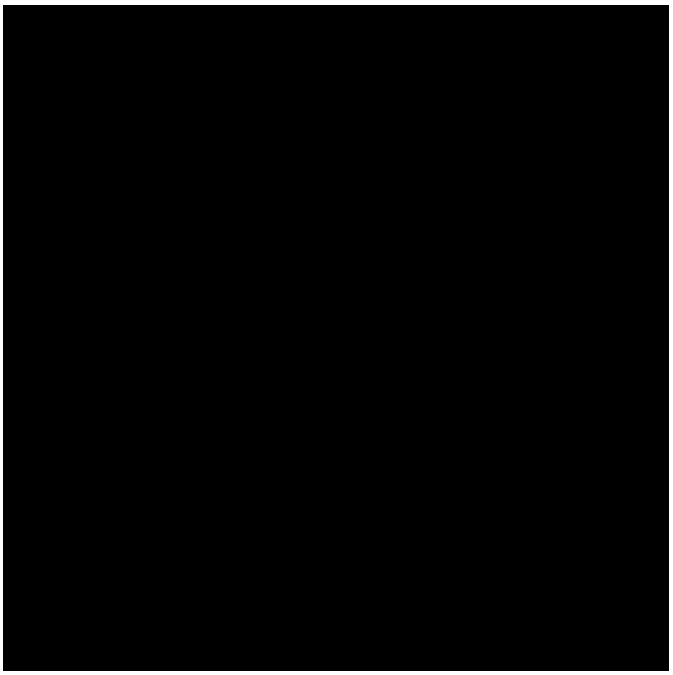

Figure A.1 – Long title of the figure

Tableau A.1 – Les paramètres du module photovoltaïque

Paramètres	Valeurs	Unités
P_{mp}	100	W
V_{oc}	13.3	V
I_{sc}	9.8	A

Annexe B

Métriques d'Évaluation et Résultats Complémentaires

B.1 Définitions formelles des métriques

B.1.1 Métriques de détection d'objets

Soient TP, FP et FN le nombre de vrais positifs, faux positifs et faux négatifs respectivement, avec un seuil d'IoU δ.

Précision moyenne (AP) :

$$AP = \int_0^1 P(R)\, dR$$

où $P(R)$ est la courbe précision-rappel interpolée.

Précision moyenne globale (mAP) :

$$\mathrm{mAP}_\delta = \frac{1}{|\mathcal{C}|} \sum_{c \in \mathcal{C}} AP_c(\delta)$$

IoU d'une boîte englobante :

$$\mathrm{IoU}(B_{pred}, B_{gt}) = \frac{|B_{pred} \cap B_{gt}|}{|B_{pred} \cup B_{gt}|}$$

B.1.2 Métriques de classification

Pour un problème de classification multi-classes à K classes :

Precision macro-moyenne :

$$P_{macro} = \frac{1}{K} \sum_{k=1}^{K} \frac{TP_k}{TP_k + FP_k}$$

Rappel macro-moyen :

$$R_{macro} = \frac{1}{K} \sum_{k=1}^{K} \frac{TP_k}{TP_k + FN_k}$$

F1-score macro-moyen :

$$F_{1,macro} = \frac{2 \cdot P_{macro} \cdot R_{macro}}{P_{macro} + R_{macro}}$$

B.2 Résultats par classe – Tableau détaillé

Tableau B.1 – Résultats de classification par classe (ResNet-50, jeu de test)

Classe	**Support (nb images)**	**Précision**	**Rappel**	**F1**
bonne combustion (`good`)	[XX]	[X.XX]	[X.XX]	[X.XX]
combustion partielle (`moderate`)	[XX]	[X.XX]	[X.XX]	[X.XX]
mauvaise combustion (`poor`)	[XX]	[X.XX]	[X.XX]	[X.XX]
Macro-moyenne	[XX]	[X.XX]	[X.XX]	[X.XX]

B.3 Courbes Précision-Rappel

[Insérer ici les courbes PR pour chaque classe et pour le modèle global]

Figure B.1 – Courbes précision-rappel du module B – ResNet-50 (une courbe par classe + courbe moyenne)